

Etapa II

COMPONENTE CURRICULAR	Projeto Aplicado I
GRUPO	Grupo 9
	Caio Felipe Correa (10764072)
	Jennifer Lins Baia da Silva (10756227)
	Nilton Cesar Marques dos Santos (10733175)

Github: <https://github.com/nltncsr/clique-economia-prefeitura-curitiba-insights>

Projeto: Análise da variabilidade de preço de itens essenciais em supermercados de uma capital brasileira

Proposta analítica e análise exploratória de dados

1 Introdução

O programa Clique Economia, da Prefeitura de Curitiba, faz uma pesquisa diária de preços nos supermercados da cidade e publica os resultados para consulta do cidadão (CURITIBA, [20–]a). A base histórica dessas coletas tem 4.396.534 registros, de 01/03/2019 a 11/09/2026.

O objetivo deste trabalho é elaborar uma análise exploratória dos preços de itens essenciais coletados pelo Clique Economia entre 2019 e 2026, para identificar como esses preços variam no tempo e entre redes. O tema se liga ao ODS 2 (Fome Zero e Agricultura Sustentável), pelo custo da cesta básica, e ao ODS 10 (Redução das Desigualdades), pelas diferenças de preço entre redes. O código da análise está no notebook `scripts/exploration.ipynb` do repositório do grupo.

2 Proposta analítica

2.1 Apresentação da organização

Os dados pertencem à Prefeitura de Curitiba e são produzidos pela Secretaria Municipal de Segurança Alimentar e Nutricional (SMSAN). Ela é responsável por garantir o acesso da população a alimentos de qualidade a preços baixos e por coordenar a rede de abastecimento e de combate à fome na capital (CURITIBA, [20–]c). A secretaria mantém 35 unidades do Armazém da Família, que vendem alimentos a preço reduzido (CURITIBA, [20–]b), e o Clique Economia, apontado pela Prefeitura como o principal serviço de apoio ao consumidor na área de segurança alimentar (CURITIBA, [20–]a). Em 2013, o serviço já informava diariamente o preço de 270 itens em 16 supermercados (PREFEITURA..., 2013).

Por ser um órgão público, a SMSAN não tem *market share* nem concorrentes, e as fontes consultadas não informam missão formal nem número de servidores. Em dados, a Prefeitura publica a base no Portal de Dados Abertos de Curitiba (CURITIBA, 2026), e o próprio programa já divulgou comparações pontuais: em 2022, mostrou que o preço de itens da cesta básica chegava a variar 100,84% de um estabelecimento para outro (PREÇO..., 2022). A versão do conjunto usada aqui foi obtida no Kaggle (PAULUGLADSON, [20–]).

2.2 Problema do estudo

A consulta diária do Clique Economia mostra onde um item está mais barato hoje. Com sete anos de coletas, é possível responder perguntas que essa consulta não responde:

- a) como o preço de arroz, feijão, açúcar e óleo evoluiu entre 2019 e 2026?
- b) há redes consistentemente mais baratas ou mais caras para esses itens?
- c) quanto custa uma cesta padrão em cada rede?
- d) quais registros são erros de coleta e quais são preços legítimos fora do padrão?

O problema segue os pilares do pensamento computacional. A decomposição separa as qua-

tro perguntas acima, que são os eixos da proposta. O reconhecimento de padrões busca tendências nas séries e redes que se repetem nos extremos do ranking. A abstração descarta `preco_atacado_qtd`, que vale sempre zero, e `codigo_categoria`, que não tem dicionário, e reduz os quatro preços a um único preço efetivo. O algoritmo é o *pipeline* da seção 2.5. A comparação por bairro, prevista na Etapa 1, saiu do escopo porque a base não informa o endereço dos estabelecimentos.

2.3 Metadados

A Tabela 1 traz os metadados do conjunto e a Tabela 2 atualiza o dicionário de dados da Etapa 1 com o que a análise revelou.

Tabela 1 – Metadados do conjunto de dados

Aspecto	Descrição
Tipo de arquivo	CSV com separador ponto e vírgula (<code>final.csv</code>), compactado em ZIP (cerca de 56 MB)
Tamanho	4.396.534 registros e 11 colunas
Origem	Portal de Dados Abertos de Curitiba; versão consolidada obtida no Kaggle
Proprietário	Prefeitura Municipal de Curitiba, por meio da SMSAN
Sensibilidade	Dado público, sem restrição de acesso
Validade temporal	Coletas de 01/03/2019 a 11/09/2026; a base é atualizada periodicamente com novas coletas
LGPD	Não há dado pessoal: os registros descrevem produtos, preços e estabelecimentos comerciais, sem identificar pessoas físicas

Tabela 2 – Dicionário de dados

Coluna	Descrição	Tipo
<code>data_pesquisa</code>	Data da coleta do preço no estabelecimento	Data
<code>id_empresa</code>	Identificador da filial. Não é único no conjunto: o mesmo número aparece em redes diferentes (seção 3.2)	Inteiro (ID), com nulos
<code>rede</code>	Nome da rede de supermercados, com variações de grafia	Texto (categórico)
<code>codigo_categoria</code>	Código da categoria do produto (0 a 9), sem dicionário que explique cada código	Inteiro (ID), com nulos
<code>id_produto</code>	Código do produto, em geral EAN-13; alguns itens usam códigos curtos	Inteiro (ID)
<code>descricao</code>	Nome, marca e tamanho do produto, em texto livre	Texto
<code>preco_regular</code>	Preço padrão de venda	Decimal (R\$)
<code>preco_atacado</code>	Preço para compra em quantidade	Decimal (R\$)
<code>preco_atacado_qtd</code>	Quantidade mínima para o preço de atacado; vale zero em todos os registros	Inteiro
<code>preco_promocao</code>	Preço em oferta temporária	Decimal (R\$)
<code>preco_fidelidade</code>	Preço exclusivo para clientes de programa de fidelidade	Decimal (R\$)
<code>preco_efetivo</code>	Coluna derivada criada pelo grupo: o preço que o consumidor comum paga (seção 3.3)	Decimal (R\$)


2.4 Proposta do que será desenvolvido

Os quatro eixos da Etapa 1 continuam: (a) séries mensais do preço dos itens essenciais; (b) ranking de preço por rede; (c) custo de uma cesta padrão por rede; e (d) regras para separar erros de coleta de preços altos legítimos. Esta etapa entrega a limpeza dos dados, o preço efetivo, as regras de anomalia, as séries de preço por quilo dos itens essenciais, o custo da cesta básica e a comparação da cesta entre redes (seção 3.7). A narrativa de *data storytelling* fica para a Etapa 3.

2.5 Pipeline de dados

O arquivo completo é lido em blocos de 500 mil linhas, o que permite calcular as estatísticas de todos os registros sem carregá-lo inteiro na memória. As análises detalhadas usam uma amostra aleatória de cerca de 10%, com semente fixa para que o resultado se repita (Figura 1).

Figura 1 – Pipeline de dados da análise



2.6 Limitações

Além do que a Etapa 1 já apontava (só Curitiba e sem endereço dos estabelecimentos), a análise encontrou:

- a) nomes de rede com variações de grafia e codificação (“Assai” e “Assaa”), sem identificador de rede para corrigi-los;
- b) códigos de categoria sem descrição;

- c) `preco_atacado_qtd` igual a zero em todos os registros;
- d) poucos registros em 2019 e 2020 (menos de 2% do total);
- e) até março de 2023, a pesquisa registrava produtos genéricos, sem marca nem tamanho de embalagem, e a comparação de preço por quilo só é possível a partir de abril de 2023.

2.7 Cronograma

O cronograma da Etapa 1 continua válido (Tabela 3).

Tabela 3 – Cronograma do projeto

Data	Tarefa	Responsável	Detalhes da execução
14/09/2026	1.1 Redação do documento	Todos	Definir título, contexto e formalizar o uso dos dados públicos do Clique Economia para fins educacionais
14/09/2026	1.2 Configuração do ambiente	Nilton	Criar o repositório no GitHub, baixar o dataset e enviá-lo ao repositório
14/09/2026	1.3 Revisão e submissão	Jennifer	Revisar a formatação do texto final e realizar a entrega oficial da etapa
Prazo 2	2.1 Limpeza e preparação	Jennifer	Tratar valores nulos, converter datas e estruturar as colunas numéricas com <i>scripts</i>
Prazo 2	2.2 Outliers e série temporal	Nilton	Isolar preços discrepantes e gerar gráficos de linha com a evolução mensal de itens essenciais
Prazo 2	2.3 Cesta e competitividade	Jennifer	Filtrar a cesta básica padrão e mapear a média de preços por rede
Prazo 2	2.4 Consolidação da AED	Nilton	Unir as análises e os gráficos em um <i>script</i> e em relatório documentado
Prazo 3	3.1 Roteirização do vídeo	Jennifer	Roteiro de 5 minutos: 1 min de introdução, 3 min com as análises e 1 min de conclusão
Prazo 3	3.2 Gravação	Todos	Gravar a tela com a execução do código e os gráficos gerados na Etapa 2
Prazo 3	3.3 Edição e submissão	Nilton	Unir as gravações, garantir o limite de 5 minutos e fazer a entrega final

3 Análise exploratória de dados

3.1 Procedimento

A análise foi feita em Python (pandas, NumPy, Matplotlib e seaborn), num notebook Jupyter. As Tabelas 4 a 6 usam o conjunto completo; o restante usa a amostra de 439.996 registros, que preserva a proporção de nulos (11,17% em `id_empresa`, contra 11,19% no conjunto, e 1,70% em `codigo_categoria` nos dois). Antes das medidas da seção 3.5, foram removidos 25 registros com preço efetivo abaixo de R\$ 0,30 (seção 3.4); outros 6 não têm nenhum preço e ficam sem preço efetivo. A cesta básica (seção 3.7) usa o conjunto completo, a partir de abril de 2023.

3.2 Descrição das variáveis

As Tabelas 4 a 6 resumem as 11 colunas: distribuição no tempo, exemplares, ausentes, valores únicos, extremos e, para os campos de valor, média, variância e desvio. Os identificadores não têm média nem variância, porque a diferença entre dois códigos não representa uma grandeza.

Tabela 4 – Registros por ano de coleta (conjunto completo)

Ano	Registros	% do total
2019	25.980	0,59
2020	57.213	1,30
2021	359.129	8,17
2022	355.950	8,10
2023	767.498	17,46
2024	730.012	16,60
2025	1.375.406	31,28
2026	725.346	16,50
Total	4.396.534	100,00

Tabela 5 – Exemplares, ausentes, valores únicos e extremos por coluna (conjunto completo)

Coluna	Exemplares	Ausentes (%)	Únicos	Mínimo	Máximo
data_pesquisa	4.396.534	0 (0,00)	–	01/03/2019	11/09/2026
id_empresa	3.904.457	492.077 (11,19)	93	0	175
rede	4.396.534	0 (0,00)	100	–	–
codigo_categoria	4.321.627	74.907 (1,70)	10	0	9
id_produto	4.396.534	0 (0,00)	2.270	89	9.002.490.209.346
descricao	4.396.534	0 (0,00)	2.771	–	–
preco_regular	4.396.534	0 (0,00)	–	0,00	549,90
preco_atacado	4.396.534	0 (0,00)	–	0,00	95,99
preco_atacado_qtd	4.396.534	0 (0,00)	–	0	0
preco_promocao	4.396.534	0 (0,00)	–	0,00	109,90
preco_fidelidade	4.396.534	0 (0,00)	–	0,00	62,90

Nota: “–” indica medida que não se aplica ou não foi calculada para a coluna.

Tabela 6 – Média, variância e desvio padrão dos campos de valor (conjunto completo)

Coluna	Média (R\$)	Variância	Desvio padrão (R\$)
preco_regular	10,55	117,54	10,84
preco_atacado	0,06	0,72	0,85
preco_atacado_qtd	0,00	0,00	0,00
preco_promocao	0,12	1,84	1,36
preco_fidelidade	0,03	0,37	0,60

Nota: variância amostral; para preco_atacado_qtd, a unidade é quantidade de itens, não reais.

data_pesquisa: sem ausentes, cobre 2.751 dias. A distribuição é desigual: 2019 e 2020 somam 1,89% dos registros, e 2023 a 2025 concentram 65,34%. Os dois anos das pontas são parciais.

id_empresa: a coluna com mais ausentes (11,19%), com 93 códigos de 0 a 175. Não identifica a filial sozinha: na amostra, 34,78% dos códigos aparecem em mais de uma rede (o código 6, por exemplo, em Condor e Stall). A filial é o par `id_empresa` e `rede`. Os nulos foram mantidos, porque nenhuma análise depende de filial.

rede: sem ausentes, com 100 nomes. Parte são variações de grafia ou codificação da mesma rede (“Assai” e “Assaa”, “Araucaria” e “Arauca!ria”), mantidas por falta de um identificador de rede. A rede Condor tem 15,83% da amostra, quase o dobro da Jacomar (Figura 3). O nome “Smsan” provavelmente corresponde às unidades da própria secretaria, o que ainda precisa ser confirmado.

codigo_categoria: 1,70% de ausentes e 10 códigos, de 0 a 9. É estável por produto (97,37% dos produtos da amostra têm um único código), mas não há dicionário que diga o que cada código significa, o que limita o uso.

id_produto: sem ausentes, com 2.270 códigos. 60,09% seguem o padrão EAN-13 e o restante são códigos curtos, provavelmente internos. É mais confiável que a descrição: na amostra, 17,09% dos produtos têm de duas a cinco descrições diferentes.

descricao: sem ausentes, com 2.771 textos, 501 a mais que o número de produtos, por variações de espaço, abreviação e codificação (“Acucar cristal” e “Aaacar cristal”). Segue o padrão nome, marca e tamanho, e foi a base para selecionar os itens essenciais.

preco_regular: média de R\$ 10,55, desvio de R\$ 10,84 e máximo de R\$ 549,90. É o único preço em 97,02% da amostra. O zero aparece quando o item só tem outro tipo de preço, como promoção (1,54%). A distribuição é assimétrica à direita (mediana de R\$ 6,98).

preco_atacado: presente em 0,94% da amostra; o zero indica que não há preço de atacado. Concentra-se em atacarejos, como a Jumbo atacadista (32,55% dos registros da rede).

preco_atacado_qtd: zero em todos os registros. Sem variação, foi excluído das análises.

preco_promocao: o preço especial mais comum, em 1,77% da amostra, de 7,24% dos registros na Zimmer supermercado a 2,78% no Condor.

preco_fidelidade: presente em 0,34% da amostra, concentrado nas variações de nome da rede Condor.

3.3 Valores ausentes

Só `id_empresa` e `codigo_categoria` têm ausentes, e nenhuma das duas foi imputada: a primeira não é usada sozinha e a segunda não tem dicionário que permita deduzir um valor. Nos preços, o zero faz o papel de ausente (Tabela 7).

Tabela 7 – Combinações de preços preenchidos (amostra, 439.996 registros)

Regular	Atacado	Promoção	Fidelidade	Registros	%
sim	–	–	–	426.899	97,02
–	–	sim	–	6.791	1,54
sim	sim	–	–	4.037	0,92
sim	–	–	sim	1.161	0,26
sim	–	sim	–	759	0,17
demais combinações (9)				349	0,08

Nota: “sim” indica preço maior que zero; entre as demais combinações, 6 registros não têm nenhum preço.

Como 6.791 registros têm promoção sem preço regular, o grupo criou a coluna `preco_efetivo`, que usa o primeiro preço disponível na ordem promoção, regular, fidelidade e atacado. A promoção vem primeiro porque é o que qualquer cliente paga durante a oferta; fidelidade e atacado ficam por último porque exigem cadastro ou compra em quantidade. Os 6 registros sem nenhum preço foram removidos.

3.4 Outliers

Pelo critério do intervalo interquartil ($Q_1 - 1,5 \cdot IQR$ e $Q_3 + 1,5 \cdot IQR$), o preço efetivo tem limites de $-8,75$ e R\$ 26,02, e 33.922 registros (7,71%) ficam acima. São principalmente carnes, como patinho (R\$ 439,99) e filé-mignon (R\$ 135,00 a R\$ 155,90), mantidas por serem preços reais. A exceção é uma “Cerveja antartica lata” a R\$ 212,19, que deve ser revisada.

Como o limite inferior é negativo, o IQR não detecta preços impossíveis. A Tabela 8 mostra os valores baixos: até R\$ 0,30 há 25 registros, como açúcar e contrafilé a centavos; acima disso surgem preços plausíveis para itens pequenos, como cheiro-verde. Esses 25 registros foram removidos.

Tabela 8 – Registros com preço efetivo até cada limiar (amostra)

Limiar (R\$)	Registros	% da amostra
0,01	3	0,0007
0,05	14	0,0032
0,10	16	0,0036
0,20	17	0,0039
0,30	25	0,0057
0,50	47	0,0107
0,70	146	0,0332
1,00	1.695	0,3852
1,50	6.640	1,5091
2,00	19.715	4,4808

3.5 Medidas de posição e dispersão

Tabela 9 – Medidas de posição e dispersão dos preços (amostra limpa, em R\$)

Coluna	Média	Moda	Mín.	Q1	Mediana	Q3	Máx.	Amplitude	Desvio	CV
preco_regular	10,54	4,99	0,00	4,18	6,98	12,90	439,99	439,99	10,85	1,03
preco_atacado	0,06	0,00	0,00	0,00	0,00	0,00	55,90	55,90	0,84	13,53
preco_promocao	0,12	0,00	0,00	0,00	0,00	0,00	89,99	89,99	1,36	11,09
preco_fidelidade	0,03	0,00	0,00	0,00	0,00	0,00	45,90	45,90	0,64	22,86
preco_efetivo	10,64	4,99	0,32	4,29	6,98	12,98	439,99	439,67	10,81	1,02

Nota: CV é adimensional; a variância do preço efetivo é 116,85.

Tabela 10 – Quartis, decis e percentis do preço efetivo (amostra limpa, em R\$)

Decil	Valor	Decil	Valor	Percentil	Valor
10%	2,98	60%	8,39	1%	1,39
20%	3,98	70%	10,98	5%	2,25
30%	4,85	80%	14,99	95%	31,98
40%	5,79	90%	22,99	99%	54,90
50% (mediana)	6,98				


Nota: os quartis são 4,29 (Q1), 6,98 (Q2) e 12,98 (Q3).

A mediana do preço efetivo (R\$ 6,98) abaixo da média (R\$ 10,64) indica assimetria à direita. Metade dos registros custa entre R\$ 4,29 e R\$ 12,98, e a cauda superior cresce rápido: do percentil 95% para o 99%, o preço sobe 72%. Nos preços especiais, moda, mediana e quartis são zero, e o coeficiente de variação passa de 11 só porque a média é quase zero. O preço efetivo fica próximo do regular; a média um pouco maior e o desvio um pouco menor vêm da troca dos zeros do preço regular pelos outros preços disponíveis.

3.6 Visualizações


O preço efetivo se concentra abaixo de R\$ 20, com uma cauda longa de itens caros (Figura 2). A barra em R\$ 100 reúne todos os valores acima desse limite.

Figura 2 – Distribuição do preço efetivo (valores limitados a R\$ 100)




A cobertura da pesquisa é desigual entre redes (Figura 3), o que pesa em qualquer média calculada sobre o conjunto inteiro.

Figura 3 – Redes com mais registros de preço na amostra



A correlação entre os quatro preços originais fica entre $-0,06$ e $0,05$ (Figura 4), o que é esperado, já que os preços especiais valem zero na maior parte dos registros.

Figura 4 – Correlação entre as variáveis de preço



3.7 Cesta básica com produtos padronizados

O problema. Na amostra, 46.865 registros têm arroz, feijão, açúcar ou óleo na descrição. Parte deles são outros produtos em que a palavra aparece no meio do nome, como farinha e massa de arroz, sardinha em óleo e refrigerante “sem açúcar”. Entre os que começam pelo item, há tipos de preço muito diferente (arroz polido e integral, óleo de soja e de canola) e embalagens de 1 kg e de 5 kg na mesma média.

O tamanho da embalagem. Até 2022, a pesquisa registrava produtos genéricos, sem marca nem embalagem (ex.: “Arroz polido”). Em março de 2023, os códigos de produto foram substituídos por códigos com marca e tamanho, e nenhum código antigo continuou em uso (Tabela 11). Abril de 2023 é o primeiro mês em que praticamente todos os registros trazem tamanho; a exceção são 5 registros de junho. Sem o tamanho não há como calcular o preço por quilo, e por isso a cesta começa em abril de 2023.

Tabela 11 – Registros com tamanho de embalagem na descrição (amostra)


Ano	Registros	% com tamanho	Mês de 2023	% com tamanho
2019	2.581	3,22	janeiro	4,37
2020	5.730	3,53	fevereiro	3,92
2021	35.907	3,73	março	18,22
2022	35.609	4,66	abril	100,00
2023	76.854	87,76	maio	100,00
2024	73.011	100,00	junho	99,96
2025	137.580	100,00	julho a dezembro	100,00
2026	72.693	100,00		

O método. A cesta usa a prática comum em pesquisas de preço: comparar produtos definidos, com o preço convertido para a mesma unidade. Os itens são selecionados por regras que

exigem a descrição começando pelo item e por um dos tipos aceitos: arroz polido ou parboilizado; feijão carioca, preto, de cor ou vermelho; açúcar refinado ou cristal; e óleo de soja, de canola ou sem tipo informado. A seleção é feita no conjunto completo e resulta em 98 produtos e 324.879 registros a partir de abril de 2023. O preço efetivo de cada registro é dividido pelo tamanho da embalagem, e a série usa a mediana mensal do preço por quilo (por litro, no óleo). O custo da cesta multiplica esse preço pelas quantidades mensais do Decreto-Lei 399/1938 para a Região 3, que inclui o Paraná: 3 kg de arroz, 4,5 kg de feijão, 3 kg de açúcar e 900 g de óleo (DIEESE, [20–]). A cesta tem só os quatro itens deste estudo, e não os 13 da cesta do DIEESE, então os valores não são comparáveis aos divulgados por ele.


Preço por quilo. O arroz sobe de R\$ 4,59/kg em abril de 2023 para R\$ 6,60 em setembro de 2024 e volta a R\$ 4,79 em setembro de 2026. O feijão tem máximo de R\$ 8,49/kg em fevereiro de 2024; o açúcar fica perto de R\$ 4,00/kg e cai para R\$ 3,38; e o óleo chega a R\$ 8,88/l em novembro de 2025 (Figura 5).

Figura 5 – Preço mediano por quilo dos itens essenciais (óleo: por litro)




Custo da cesta. A cesta de quatro itens custa R\$ 67,78 em abril de 2023, chega a R\$ 74,34 em fevereiro de 2024, puxada pelo pico do feijão, e fecha em R\$ 63,21 em setembro de 2026 (Figura 6).

Figura 6 – Custo mensal da cesta de quatro itens em Curitiba



Comparação entre redes. Entre outubro de 2025 e setembro de 2026, 34 redes têm pelo menos 20 registros de cada item. A cesta vai de R\$ 53,05 na Max Atacadista a R\$ 73,83 na Michel, uma diferença de 39,2% (Figura 7).

Figura 7 – Custo da cesta por rede (outubro de 2025 a setembro de 2026)



A mediana de cada item reúne todos os tipos e marcas vendidos na rede. Como o óleo de canola custa cerca de 1,7 vez o de soja por litro, e o feijão vermelho, quase o dobro do preto, parte da diferença entre redes vem do mix de produtos que cada uma vende, e não só do preço cobrado.

4 Considerações finais

A base é grande e quase completa: só duas colunas têm ausentes, e nenhuma é central para o estudo. Os cuidados estão em outros pontos: preços sobrepostos, resolvidos com o preço efetivo; identificador de filial que não é único; nomes de rede inconsistentes; alguns preços

impossíveis, já removidos; e a troca de códigos de março de 2023, que deixa a comparação por quilo possível só a partir de abril daquele ano.

Com produtos padronizados, a cesta de arroz, feijão, açúcar e óleo teve pico de R\$ 74,34 em fevereiro de 2024 e fechou setembro de 2026 em R\$ 63,21. Nos últimos 12 meses, a mesma cesta custou de R\$ 53,05 a R\$ 73,83, dependendo da rede, uma diferença de 39,2% que o consumidor não vê na consulta diária do Clique Economia.

Referências

CURITIBA. Prefeitura Municipal. *Dados Abertos de Curitiba*. Curitiba, 2026. Disponível em: <https://dadosabertos.curitiba.pr.gov.br/>. Acesso em: 1 out. 2026.

CURITIBA. Prefeitura Municipal. *Do Clique Economia aos Armazéns da Família, conheça os aliados do consumidor de Curitiba*. Curitiba, [20–]a. Disponível em: <https://www.curitiba.pr.gov.br/noticias/do-clique-economia-aos-armazens-da-familia-conheca-os-aliados-do-consumidor-de-curitiba/67679>. Acesso em: 1 out. 2026.

CURITIBA. Prefeitura Municipal. *Programa Armazém da Família completa 35 anos de sucesso em Curitiba*. Curitiba, [20–]b. Disponível em: <https://www.curitiba.pr.gov.br/noticias/programa-armazem-da-familia-completa-35-anos-de-sucesso-em-curitiba/74313>. Acesso em: 1 out. 2026.

CURITIBA. Prefeitura Municipal. *Secretaria Municipal de Segurança Alimentar e Nutricional*. Curitiba, [20–]c. Disponível em: <https://www.curitiba.pr.gov.br/locais/secretaria-municipal-de-seguranca-alimentar-e-nutricional/831>. Acesso em: 1 out. 2026.

DIEESE. *Metodologia da Cesta Básica de Alimentos*. São Paulo, [20–]. Disponível em: <https://www.dieese.org.br/metodologia/metodologiaCestaBasica/1.html>. Acesso em: 1 out. 2026.

PAULOGLADSON. *Clique Economia Dados (Curitiba)*. [S. l.]: Kaggle, [20–]. Disponível em: <https://www.kaggle.com/datasets/paulogladson/clickeconomiadados>. Acesso em: 1 out. 2026.

PREÇO de alimentos pode variar até 100% entre supermercados de Curitiba. *Tribuna do Paraná*, Curitiba, 8 abr. 2022. Disponível em: <https://www.tribunapr.com.br/noticias/curitiba-regiao/preco-de-alimentos-pode-variatar-ate-100-entre-supermercados-de-curitiba/>. Acesso em: 1 out. 2026.

PREFEITURA de Curitiba pesquisa e informa preços de 270 produtos. *Tribuna do Paraná*, Curitiba, 20 jan. 2013. Disponível em: <https://www.tribunapr.com.br/noticias/prefeitura-de-curitiba-pesquisa-e-informa-precos-de-270-produtos/>. Acesso em: 1 out. 2026.

Glossário

AED: Análise exploratória de dados.

Amostra: Subconjunto de registros sorteado do conjunto completo. Aqui, cerca de 10% dos registros, sorteados com semente fixa para que o resultado se repita.

Assimetria à direita: Distribuição em que poucos valores muito altos puxam a média para cima, deixando-a acima da mediana.

Bloco (*chunk*): Parte do arquivo lida de cada vez, usada para processar o conjunto inteiro sem carregá-lo todo na memória.

Cesta básica: Conjunto padrão de alimentos usado como referência para medir o custo da alimentação de uma família.

Coefficiente de variação: Razão entre o desvio padrão e a média. Mede a dispersão relativa e permite comparar variáveis de escalas diferentes.

Dados abertos: Dados públicos disponibilizados para livre consulta e reutilização.

EAN-13: Padrão de código de barras de 13 dígitos usado para identificar produtos no varejo.

Interpolação linear: Estimativa de um valor ausente a partir da reta entre os valores vizinhos conhecidos.

Intervalo interquartil: Diferença entre o terceiro e o primeiro quartil. Concentra a metade central dos dados e é a base do critério de outliers usado neste trabalho.

IQR: Intervalo interquartil (*interquartile range*).

LGPD: Lei Geral de Proteção de Dados Pessoais.

Notebook Jupyter: Arquivo que combina código, resultados e texto explicativo, executado célula a célula.

ODS: Objetivos de Desenvolvimento Sustentável, da ONU.

Outlier: Valor muito distante dos demais. Pode ser erro de coleta ou um valor legítimo e raro.

Pipeline de dados: Sequência de etapas pela qual os dados passam, da leitura até o resultado final.

Preço efetivo: Coluna criada pelo grupo com um único preço por registro, escolhido entre promoção, regular, fidelidade e atacado, nessa ordem.

Quartil, decil e percentil: Separatrizes que dividem os dados ordenados em 4, 10 e 100 partes iguais.

Rede: Empresa de supermercados que pode ter várias lojas (filiais).

Série temporal: Sequência de valores medidos em intervalos regulares de tempo, como a média mensal de um preço.

SMSAN: Secretaria Municipal de Segurança Alimentar e Nutricional de Curitiba.